Clases - Semana 2

September 27, 2020

1 The Series Data Structure

```
[4]: import pandas as pd
 [5]: students = ['Alice', 'Jack', 'Molly'] #creo una serie pasandole una lista
     pd.Series(students)
[5]: 0
          Alice
     1
           Jack
          Molly
     2
     dtype: object
 [6]: numbers = [1, 2, 3]
     pd.Series(numbers)
 [6]: 0
          1
     1
          2
          3
     dtype: int64
 [7]: students = ['Alice', 'Jack', None] #puedo asignar valores vacios
     pd.Series(students)
[7]: 0
          Alice
           Jack
     1
           None
     dtype: object
 [8]: numbers = [1, 2, None]
     pd.Series(numbers) #pandas convierte el tipo a float, porque falta un valor
 [8]: 0
          1.0
          2.0
     1
          NaN
     dtype: float64
 [9]: | #Nan no es lo mismo que None (son muy similares), se tratan distinto por
      ⇔razones de eficiencia.
[10]: #NaN: not a number
     import numpy as np
     np.nan == None #no se puede igualar un Nan por si mismo, siempre sera False
```

```
[10]: False
[11]: np.nan == np.nan #esto tambien da False
[11]: False
[12]: #hay que usar funciones para detectar un NaN:
     np.isnan(np.nan)
[12]: True
[13]: students_score = {'Alice': 'Physics', #creo una serie con un diccionario.
                       'Jack': 'Chemistry',
                       'Molly': 'English'}
     s = pd.Series(students_score)
     s
[13]: Alice
                Physics
     Jack
              Chemistry
    Molly
                English
     dtype: object
[14]: s.index #los index tambien pueden ser string, con esta funcion los veo
[14]: Index(['Alice', 'Jack', 'Molly'], dtype='object')
[15]: students = [('Alice', 'Brown'), ('Jack', 'White'), ('Molly', 'Green')] #haqou
      →una serie con una lista de tuplas
     pd.Series(students)
[15]: 0
          (Alice, Brown)
           (Jack, White)
     2
          (Molly, Green)
     dtype: object
[16]: #se puede pasar el index cuando se crea la serie:
     s = pd.Series(['Physics', 'Chemistry', 'English'], index = ['Alice', 'Jack', _
      →'Molly'])
     s
[16]: Alice
                Physics
     Jack
              Chemistry
     Molly
                English
     dtype: object
[17]: #si creo una serie con un diccionario y el index que le pongo no coincide con
     → las keys del dict, los valores del index
     #que no sean keys del dict se llenaran con NaN. Por otro lado las keys que no⊔
     →esten en el index no apareceran en la serie
     students_score = {'Alice': 'Physics',
                       'Jack': 'Chemistry',
                       'Molly': 'English'}
     s = pd.Series(students_score, index = ['Alice', 'Jack', 'Sam'])
```

```
s #aparece Sam y no aparece Molly
[17]: Alice
                Physics
     Jack
              Chemistry
     Sam
                     NaN
     dtype: object
        Queryng a Series
[18]: import pandas as pd
     students_classes = {'Alice': 'Physics',
                        'Jack': 'Chemistry',
                        'Molly': 'English',
                        'Sam': 'History'}
     s = pd.Series(students_classes)
     s
[18]: Alice
                Physics
              Chemistry
     Jack
                 English
     Molly
     Sam
                History
     dtype: object
[19]: #el iloc se utiliza para ver una posicion numerica (index position)
     s.iloc[3]
[19]: 'History'
[20]: #el loc se utiliza para ver una posicion por la etiqueta del index (index
      \rightarrow label)
     s.loc['Molly']
[20]: 'English'
[21]: #iloc y loc son atributos (y no metodos), por eso se usan corchetes.
     #lo mismo se puede hacer de la siguiente manera:
     s[3]
[21]: 'History'
[22]: s['Molly']
[22]: 'English'
       Si tengo numeros enteros como index, como sabe pandas si me refiero a index position o index
    label? Por eso siempre es recomendable usar loc y iloc.
[23]: class_code = {99: 'Physics',
                   100: 'Chemistry',
                   101: 'English',
                   102: 'History'}
```

s = pd.Series(class_code)

```
[24]: #en este caso poner: s[0] tiraria error porque no hay ningun item con index 0.
      →Para eso tenemos que usar iloc:
     s.iloc[0]
[24]: 'Physics'
[25]: #ejemplo de una serie con notas de alumnos y el calculo del promedio:
     grades = pd.Series([90, 80, 70, 60])
     total = 0
     for grade in grades:
         total += grade
     print(total/len(grades))
    75.0
[26]: #esto se puede hacer de manera mas sencilla usando numpy
     import numpy as np
     total = np.sum(grades)
     print(total/len(grades))
    75.0
[27]: #Ahora veamos cual de los dos metodos es mas rapido, usando una serie de mayoru
      → tamaño:
     numbers = pd.Series(np.random.randint(0, 1000, 10000)) #estoy pidiendo 10.000
      →numeros enteros random entre 0 y 1000
     numbers.head() #veo los primeros 5 valores
[27]: 0
          663
     1
          845
     2
          517
     3
          698
          939
     dtype: int64
[28]: \%\timeit -n 100
     total = 0
     for number in numbers:
         total += number
     total/len(numbers)
     #mido el tiempo con un magic para la primera opcion. El n es la cantidad de _{\!\!\! \sqcup}
      →veces que mide para luego devolver un promedio.
```

1.13 ms \$ 7.55 ts per loop (mean \$ std. dev. of 7 runs, 100 loops each)

```
[29]: %%timeit -n 100
     total = np.sum(numbers)
     total/len(numbers)
     #mido el tiempo para la segunda opcion, que es mucho mas rapida. La funcion⊔
      →magic siempre debe ser la primer linea de la celda.
    66.7 ts $ 8.3 ts per loop (mean $ std. dev. of 7 runs, 100 loops each)
[30]: numbers.head()
[30]: 0
          663
     1
          845
          517
     2
     3
          698
          939
     dtype: int64
[31]: numbers += 2 #le sumo 2 a todos los valores de la serie, no es necesario iterar
     numbers.head()
[31]: 0
          665
     1
          847
     2
          519
     3
          700
          941
     4
     dtype: int64
[32]: | #tambien se puede hacer iterando, de la siguiente manera:
     for label, value in numbers.iteritems():
         numbers.set_value(label, value+2)
     numbers.head()
[32]: 0
          667
     1
          849
     2
          521
     3
          702
          943
     4
     dtype: int64
[33]: #vamos a medir los tiempos a ver cual de las dos opciones es mas rapida:
[34]: | %%timeit -n 10
     s = pd.Series(np.random.randint(0, 1000, 1000))
     s += 2
    240 ts $ 19.2 ts per loop (mean $ std. dev. of 7 runs, 10 loops each)
[35]: %%timeit -n 10
     s = pd.Series(np.random.randint(0, 1000, 1000))
     for label, value in s.iteritems():
```

```
s.loc[label] = value + 2
    124 ms ś 2.85 ms per loop (mean ś std. dev. of 7 runs, 10 loops each)
[36]: #puedo tener distintos tipos de index y agregarlos con .loc:
     s = pd.Series([1, 2, 3])
     s.loc['History'] = 102
[36]: 0
                  1
                  2
     1
     2
                  3
    History
                102
     dtype: int64
[37]: #que pasa si los index no son unicos? aca va un ejemplo:
     students_classes = pd.Series({'Alice': 'Physics',
                       'Jack': 'Chemistry',
                       'Molly': 'English',
                       'Sam': 'History'})
     students_classes
[37]: Alice
                Physics
     Jack
              Chemistry
    Molly
                English
     Sam
                History
     dtype: object
[38]: kelly_classes = pd.Series(['Philosophy', 'Arts', 'Math'], index = ['Kelly', |
     kelly_classes
[38]: Kelly
             Philosophy
    Kelly
                    Arts
                    Math
     Kelly
     dtype: object
[39]: #ahora agrego las clases de kelly con el resto de los estudiantes
     all_students_classes = students_classes.append(kelly_classes)
     all_students_classes
[39]: Alice
                 Physics
     Jack
               Chemistry
    Molly
                 English
     Sam
                 History
    Kelly
              Philosophy
    Kelly
                    Arts
                    Math
    Kelly
     dtype: object
[40]: all_students_classes.loc['Kelly']
```

```
[40]: Kelly
             Philosophy
    Kelly
                    Arts
     Kelly
                    Math
     dtype: object
[41]: students_classes #esta sique siendo iqual, ya que con el append no se modifica
      →el valor original, sino que se devuelve otro con
                      #el agregado
[41]: Alice
                Physics
     Jack
              Chemistry
     Molly
                English
     Sam
                History
     dtype: object
        DataFrame Data Structure
[42]: import pandas as pd
[43]: #creo tres series
     record1 = pd.Series({'Name': 'Alice',
                           'Class': 'Physics',
                           'Score': 85})
     record2 = pd.Series({'Name': 'Jack',
                           'Class': 'Chemistry',
                           'Score': 82})
     record3 = pd.Series({'Name': 'Helen',
                           'Class': 'Biology',
                           'Score': 90})
[44]: #creo data frame con las series
     df = pd.DataFrame([record1, record2, record3], index = ['School 1', 'School 2', |

¬'School 1'])
     df.head()
[44]:
                Name
                          Class Score
     School 1 Alice
                        Physics
                                     85
     School 2
                      Chemistry
                                     82
                Jack
     School 1 Helen
                        Biology
                                     90
[45]: #puedo hacer lo mismo con una lista de diccionarios:
     students = [{'Name': 'Alice',
                  'Class': 'Physics',
                  'Score': 85},
                {'Name': 'Jack',
                 'Class': 'Chemistry',
                 'Score': 82},
                {'Name': 'Helen',
                 'Class': 'Biology',
```

```
'Score': 90}]
     df = pd.DataFrame(students, index = ['School 1', 'School 2', 'School 1'])
     df
[45]:
                Name
                          Class
                                 Score
     School 1 Alice
                        Physics
                                     85
     School 2
                Jack
                      Chemistry
                                     82
                                     90
     School 1 Helen
                        Biology
[46]: #para seleccionar datos puedo usar loc:
     df.loc['School 2']
[46]: Name
                   Jack
     Class
              Chemistry
     Score
                     82
     Name: School 2, dtype: object
[47]: type(df.loc['School 2']) #veo el tipo de objeto
[47]: pandas.core.series.Series
[48]: df.loc['School 1'] #obviamente los index pueden no ser unicos
                        Class Score
[48]:
                Name
     School 1 Alice Physics
                                   85
     School 1 Helen Biology
                                   90
[49]: #si quiero los nombres de los estudiantes de la escuela 1:
     df.loc['School 1', 'Name']
[49]: School 1
                 Alice
     School 1
                 Helen
     Name: Name, dtype: object
[50]: #si quiero saber los nombres de todos:
     df['Name']
     #df.loc['Name'] tira error, no se puede aplicar loc en los nombres de columnas
[50]: School 1
                 Alice
     School 2
                  Jack
     School 1
                 Helen
     Name: Name, dtype: object
[51]: df.loc['School 1']['Name'] #tambien se puede hacer de esta manera, aplico .locu
      →y despues indico las columnas que deseo
[51]: School 1
                 Alice
     School 1
                 Helen
     Name: Name, dtype: object
[52]: #si quiero todos los nombres y puntajes puedo hacer slicing:
     df.loc[:, ['Name', 'Score']]
```

```
[52]:
    School 1 Alice
                         85
     School 2
                Jack
                          82
     School 1 Helen
                         90
[53]: #para borrar puedo usar .drop. Esta funcion no cambia el df original, sino que
     →devuelve una copia
     df.drop('School 1')
[53]:
               Name
                         Class
                                 Score
     School 2 Jack Chemistry
                                    82
[54]: df #puedo ver que este df permanece igual, no se borro nada
[54]:
                Name
                          Class
                                  Score
                        Physics
     School 1 Alice
                                     85
     School 2
                Jack
                      Chemistry
                                     82
     School 1 Helen
                                     90
                        Biology
[55]: #hay dos parametros importantes: inplace e axis
     #si pongo el parametro inplace en True los datos se actualizaran en el df_{\sqcup}
      →original (en vez de hacer una copia)
     #el axis viene seteado en 0, si lo pongo en 1 voy a borrar columnas en vez de_
      \rightarrow filas
[56]: copy_df = df.copy() #creo una copia del df
     copy_df.drop('Name', inplace = True, axis = 1) #borro los nombres inplace
     copy_df
[56]:
                   Class Score
     School 1
                 Physics
                              85
     School 2
              Chemistry
                              82
     School 1
                 Biology
                              90
[57]: #usando del puedo borrar datos tambien. Esto no devuelve una vista, hace efectou
     ⇒sobre el df original
     del copy_df['Class'] #borro la columna de clases, si corro nuevamente estau
      →celda tira error (porque ya no hay que borrar)
     copy_df
[57]:
               Score
     School 1
                  85
     School 2
                  82
     School 1
                  90
[58]: | df ['Class Ranking'] = None #de esta manera puedo añadir columnas, todas con
     →valor vacio
     df
                                  Score Class Ranking
[58]:
                Name
                          Class
     School 1 Alice
                        Physics
                                     85
                                                 None
                Jack Chemistry
     School 2
                                     82
                                                 None
```

Name Score

School 1 Helen Biology 90 None

4 Data Frame Indexing and Loading

[59]: !cat Admission_Predict.csv #con !cat muestro los calores de un archivo

```
df.head()
[61]:
        Serial No. GRE Score TOEFL Score University Rating
                                                                SOP
                                                                      LOR
                                                                            CGPA \
     0
                 1
                          337
                                        118
                                                                4.5
                                                                       4.5
                                                                            9.65
                 2
                                        107
     1
                          324
                                                             4
                                                                4.0
                                                                       4.5
                                                                            8.87
     2
                 3
                          316
                                        104
                                                             3
                                                                3.0
                                                                       3.5 8.00
     3
                 4
                          322
                                                             3
                                                                3.5
                                                                       2.5 8.67
                                        110
                                                             2
     4
                 5
                          314
                                        103
                                                                2.0
                                                                       3.0 8.21
        Research Chance of Admit
     0
               1
                              0.92
                              0.76
     1
               1
     2
                              0.72
               1
     3
               1
                              0.80
               0
                              0.65
[62]: #veo que los index empiezan con 0 y el numero de serie con 1. Por eso se_{\sqcup}
     →cargara de nuevo y se pondra como index el numero de
     #serie:
     df = pd.read_csv('Admission_Predict.csv', index_col = 0)
     df.head()
```

[60]: import pandas as pd

[61]: df = pd.read_csv('Admission_Predict.csv')

```
Serial No.
     1
                       337
                                     118
                                                           4 4.5
                                                                    4.5 9.65
     2
                       324
                                     107
                                                           4
                                                              4.0
                                                                    4.5 8.87
     3
                                                              3.0
                       316
                                     104
                                                           3
                                                                    3.5 8.00
     4
                                                           3
                                                              3.5
                       322
                                     110
                                                                    2.5 8.67
     5
                       314
                                     103
                                                              2.0
                                                                    3.0 8.21
                 Research Chance of Admit
     Serial No.
                                        0.92
     1
                        1
     2
                        1
                                        0.76
     3
                                        0.72
                        1
     4
                        1
                                        0.80
     5
                                        0.65
[63]: #ahora le vamos a cambiar el nombre a las columnas SOP y LOR, por su nombre
     →completo (son siglas). Para eso es necesario crear
     #un diccionario para pasarle los nuevos nombres de columnas:
     new_df = df.rename(columns = { 'GRE Score': 'GRE Score',
                                     'TOEFL Score': 'TOEFL Score',
                                     'University Rating': 'University Rating',
                                     'SOP': 'Statement of Purpose',
                                     'LOR': 'Letter of Recomendation',
                                     'CGPA': 'CGPA',
                                     'Research': 'Research',
                                     'Chance of Admit': 'Chance of Admit'})
     new_df.head()
[63]:
                 GRE Score TOEFL Score University Rating Statement of Purpose \
    Serial No.
     1
                       337
                                     118
                                                           4
                                                                                4.5
     2
                       324
                                                           4
                                                                                4.0
                                     107
     3
                                                           3
                       316
                                     104
                                                                                3.0
                                                           3
     4
                       322
                                                                                3.5
                                     110
                       314
                                     103
                                                           2
                                                                                2.0
                 LOR
                       CGPA
                             Research Chance of Admit
     Serial No.
                  4.5 9.65
                                                    0.92
     1
                                     1
                  4.5 8.87
     2
                                     1
                                                     0.76
     3
                  3.5 8.00
                                     1
                                                     0.72
     4
                  2.5 8.67
                                                     0.80
                                     1
                  3.0 8.21
                                                     0.65
[64]: #ahora vemos que SOP cambio pero LOR no. Vamos a ver los nombres de lasu
      →columnas:
     new_df.columns
```

GRE Score TOEFL Score University Rating SOP LOR

CGPA \

[62]:

```
[64]: Index(['GRE Score', 'TOEFL Score', 'University Rating', 'Statement of Purpose',
            'LOR ', 'CGPA', 'Research', 'Chance of Admit '],
           dtype='object')
[65]: #vemos que despues de LOR hay un espacio, por eso el rename no funcionaba para
     →LOR. Renombro devuelta con el espacio:
     new_df = new_df.rename(columns = {'LOR ': 'Letter of Recomendation'})
     new_df.head()
[65]:
                 GRE Score TOEFL Score University Rating Statement of Purpose \
    Serial No.
                       337
                                                          4
     1
                                                                               4.5
                                     118
                                                          4
     2
                       324
                                    107
                                                                               4.0
     3
                       316
                                    104
                                                          3
                                                                               3.0
     4
                       322
                                    110
                                                          3
                                                                               3.5
     5
                       314
                                    103
                                                          2
                                                                               2.0
                 Letter of Recomendation CGPA Research Chance of Admit
     Serial No.
                                     4.5 9.65
                                                        1
                                                                       0.92
     1
                                     4.5 8.87
     2
                                                        1
                                                                        0.76
     3
                                      3.5 8.00
                                                                        0.72
                                                        1
     4
                                      2.5 8.67
                                                        1
                                                                        0.80
     5
                                      3.0 8.21
                                                        0
                                                                        0.65
[66]: #esto es medio fragil porque podrian haber sido dos espacios, un un tab. Para
     →esp usamos la funcion strip, que saca los
     #espacios en blanco (del final del texto). Le indico que lo haga a traves de
     → las columnas
     new_df = new_df.rename(mapper = str.strip, axis = 'columns')
     new_df.head()
[66]:
                 GRE Score TOEFL Score University Rating Statement of Purpose \
    Serial No.
     1
                       337
                                    118
                                                          4
                                                                               4.5
     2
                       324
                                                          4
                                                                               4.0
                                    107
     3
                       316
                                    104
                                                          3
                                                                               3.0
                                                          3
     4
                       322
                                    110
                                                                               3.5
                                                          2
     5
                       314
                                    103
                                                                               2.0
                 Letter of Recomendation CGPA Research Chance of Admit
    Serial No.
     1
                                     4.5 9.65
                                                        1
                                                                      0.92
     2
                                     4.5 8.87
                                                        1
                                                                      0.76
     3
                                      3.5 8.00
                                                        1
                                                                      0.72
     4
                                      2.5 8.67
                                                        1
                                                                      0.80
     5
                                      3.0 8.21
                                                        0
                                                                      0.65
```

```
[67]: #el df sique siendo el mismo, solo hay una copia en new df con los nombres de
      → las columnas cambiados:
     df.columns
[67]: Index(['GRE Score', 'TOEFL Score', 'University Rating', 'SOP', 'LOR', 'CGPA',
            'Research', 'Chance of Admit'],
           dtype='object')
[68]: #tambien puedo asignar una lista con los nombres de las columnas con df.columns.
      → En este caso estoy modificando el df original
     cols = list(df.columns) #creo una lista a partir de los nombres de columnasu
     → originales
     cols = [x.lower().strip() for x in cols] #paso todo a minuscula y elimino⊔
      ⇔espacios en blanco al final
     df.columns = cols #realizo los cambios de nombres con la lista cols
     df.head()
[68]:
                 gre score toefl score university rating sop
                                                                  lor
    Serial No.
                       337
                                                             4.5
     1
                                    118
                                                                  4.5
                                                                       9.65
     2
                       324
                                    107
                                                             4.0
                                                                  4.5 8.87
     3
                       316
                                    104
                                                             3.0
                                                                  3.5 8.00
     4
                       322
                                    110
                                                             3.5 2.5 8.67
     5
                       314
                                    103
                                                             2.0 3.0 8.21
                 research chance of admit
     Serial No.
                                      0.92
     1
                        1
                                      0.76
     2
                        1
                                      0.72
     3
                        1
     4
                                      0.80
                        1
     5
                        0
                                      0.65
```

5 Querying a DataFrame

Una boolean mask es una serie o data frame (con la misma cantidad de filas y columnas que el archivo de interes) con valores de True o False. Cuando paso la mascara por el archivo, los valores que coincidan con un True se mantendran mientras que los que coincidan con False se perderan.

```
[69]: import pandas as pd
     df = pd.read_csv('Admission_Predict.csv', index_col = 0)
     df.columns = [x.lower().strip() for x in cols]
     df.head()
[69]:
                 gre score toefl score university rating sop
                                                                 lor
                                                                      cgpa \
     Serial No.
                                                                 4.5 9.65
     1
                       337
                                    118
                                                            4.5
     2
                       324
                                    107
                                                            4.0 4.5 8.87
     3
                                                            3.0 3.5 8.00
                       316
                                    104
```

```
5
                       314
                                     103
                                                          2 2.0 3.0 8.21
                 research chance of admit
     Serial No.
                        1
                                       0.92
     1
     2
                                       0.76
                        1
     3
                        1
                                       0.72
     4
                        1
                                       0.80
     5
                        0
                                       0.65
[70]: #creo una mascara paralos estudiantes con chance of admit mayor a 0.7:
     admit_mask = df['chance of admit'] > 0.7
     admit mask
[70]: Serial No.
     1
             True
     2
             True
     3
             True
     4
             True
            False
            . . .
     396
             True
     397
             True
     398
             True
     399
            False
     400
             True
     Name: chance of admit, Length: 400, dtype: bool
[71]: #ahora podemos pasar la mascara con la funcion .where():
     df.where(admit_mask).head()
     #los valores con chance of admit menor a 0.7 no se borran, sino que aparecenu
      →como Nan
[71]:
                 gre score toefl score university rating sop lor
     Serial No.
                     337.0
                                   118.0
                                                        4.0 4.5 4.5 9.65
     1
     2
                     324.0
                                   107.0
                                                        4.0 4.0 4.5 8.87
     3
                     316.0
                                   104.0
                                                        3.0
                                                              3.0 3.5 8.00
     4
                     322.0
                                   110.0
                                                        3.0
                                                              3.5
                                                                   2.5 8.67
     5
                       NaN
                                     NaN
                                                        NaN NaN NaN
                                                                         NaN
                 research chance of admit
     Serial No.
                      1.0
                                       0.92
     1
     2
                      1.0
                                       0.76
     3
                      1.0
                                       0.72
     4
                      1.0
                                       0.80
     5
                      NaN
                                        NaN
```

4

322

110

3 3.5 2.5 8.67

```
[72]: #con el dropna() elimino todos los valores nulos
     df.where(admit mask).dropna().head()
[72]:
                 gre score toefl score university rating sop
                                                                  lor cgpa \
    Serial No.
     1
                     337.0
                                  118.0
                                                        4.0 4.5 4.5 9.65
     2
                     324.0
                                                             4.0
                                                                  4.5 8.87
                                  107.0
                                                        4.0
     3
                     316.0
                                  104.0
                                                        3.0
                                                             3.0 3.5 8.00
     4
                     322.0
                                  110.0
                                                        3.0
                                                             3.5 2.5 8.67
                     330.0
                                  115.0
                                                        5.0 4.5 3.0 9.34
     6
                 research chance of admit
     Serial No.
                      1.0
                                      0.92
     1
     2
                      1.0
                                      0.76
     3
                                      0.72
                      1.0
     4
                      1.0
                                      0.80
     6
                      1.0
                                      0.90
[73]: #con pandas se puede hacer where y dropna al mismo tiempo:
     df[admit_mask].head()
[73]:
                 gre score toefl score university rating sop
                                                                  lor
                                                                       cgpa \
    Serial No.
                       337
     1
                                    118
                                                             4.5
                                                                  4.5 9.65
    2
                       324
                                    107
                                                             4.0
                                                                  4.5 8.87
     3
                       316
                                    104
                                                             3.0
                                                                  3.5 8.00
     4
                       322
                                    110
                                                          3
                                                             3.5 2.5 8.67
     6
                       330
                                    115
                                                          5 4.5 3.0 9.34
                 research chance of admit
     Serial No.
     1
                        1
                                      0.92
     2
                                      0.76
                        1
     3
                        1
                                      0.72
     4
                                      0.80
                        1
                        1
                                      0.90
[74]: #esto tambien se puede usar para vero una o mas columnas:
     df['gre score'].head()
[74]: Serial No.
     1
          337
     2
          324
     3
          316
          322
     4
          314
     Name: gre score, dtype: int64
[75]: df[['gre score', 'toefl score']].head()
```

```
[75]:
                 gre score toefl score
    Serial No.
     1
                       337
                                     118
     2
                       324
                                     107
     3
                       316
                                     104
     4
                        322
                                     110
     5
                       314
                                     103
[77]: #le pongo directamente una mascara
     df[df['gre score'] > 320].head()
[77]:
                 gre score toefl score university rating sop lor
                                                                         cgpa \
     Serial No.
                       337
                                                              4.5
                                                                   4.5 9.65
                                     118
     2
                       324
                                                              4.0 4.5 8.87
                                     107
     4
                        322
                                                              3.5
                                                                   2.5 8.67
                                     110
     6
                       330
                                     115
                                                             4.5 3.0 9.34
                       321
                                     109
                                                              3.0
                                                                   4.0 8.20
                 research chance of admit
     Serial No.
                                       0.92
     1
                         1
     2
                         1
                                       0.76
     4
                         1
                                       0.80
     6
                         1
                                       0.90
     7
                         1
                                       0.75
[78]: #para combinar muchas mascaras puedo usar and (&) y or (/).
     (df['chance of admit'] > 0.7) & (df['chance of admit'] < 0.9)
[78]: Serial No.
     1
            False
     2
             True
     3
             True
     4
             True
     5
            False
            . . .
     396
             True
     397
             True
     398
            False
     399
            False
     400
            False
     Name: chance of admit, Length: 400, dtype: bool
[79]: #otra forma de hacerlo
     df['chance of admit'].gt(0.7) & df['chance of admit'].lt(0.9) #gt: greater than.
      → lt: lower than
[79]: Serial No.
     1
             True
```

```
2
            False
     3
            False
     4
            False
            False
             . . .
     396
            False
     397
            False
     398
              True
     399
            False
     400
              True
     Name: chance of admit, Length: 400, dtype: bool
[81]: df['chance of admit'].gt(0.7).lt(0.9) #tambien puedo encadenar gt y lt
[81]: Serial No.
     1
            False
     2
            False
     3
            False
     4
            False
              True
             . . .
     396
            False
     397
            False
     398
            False
     399
              True
     400
            False
     Name: chance of admit, Length: 400, dtype: bool
```

6 Indexing DataFrames

La funcion set_index() es destructiva y no mantiene el indice anterior, por lo que si se lo quiere conservar se debera copiar a una nueva columna antes de hacer el set_index.

```
[85]: import pandas as pd
     df = pd.read_csv('Admission_Predict.csv', index_col = 0)
     df.head()
[85]:
                                                                           CGPA
                 GRE Score
                             TOEFL Score University Rating
                                                               SOP
                                                                    LOR
     Serial No.
                                                               4.5
     1
                        337
                                      118
                                                            4
                                                                     4.5
                                                                           9.65
     2
                        324
                                      107
                                                               4.0
                                                                     4.5
                                                                          8.87
     3
                                      104
                                                            3
                                                               3.0
                                                                     3.5 8.00
                        316
     4
                        322
                                                            3
                                                               3.5
                                                                     2.5 8.67
                                      110
     5
                                                            2
                                                               2.0
                        314
                                      103
                                                                     3.0 8.21
                 Research Chance of Admit
     Serial No.
                                         0.92
     1
                         1
```

```
3
                                        0.72
                        1
                                        0.80
     4
                        1
     5
                                        0.65
                        0
[86]: #vamos a usar dei ndice el chance of admit, pero queremos conservar el numerou
     →de serie por lo que debemos hacer una copia.
     df['Serial number'] = df.index #copio el index a una nueva columna
     df = df.set_index('Chance of Admit ') #seteo chance of admit como indice
     df.head()
[86]:
                       GRE Score TOEFL Score University Rating SOP LOR
                                                                                CGPA \
     Chance of Admit
     0.92
                              337
                                                                    4.5
                                           118
                                                                          4.5
                                                                               9.65
     0.76
                              324
                                           107
                                                                 4
                                                                    4.0
                                                                          4.5 8.87
     0.72
                              316
                                           104
                                                                 3
                                                                    3.0
                                                                          3.5 8.00
     0.80
                              322
                                           110
                                                                    3.5
                                                                          2.5 8.67
     0.65
                                                                 2 2.0
                              314
                                           103
                                                                           3.0 8.21
                       Research Serial number
     Chance of Admit
     0.92
                               1
                                              1
     0.76
                                              2
                               1
     0.72
                                              3
                               1
     0.80
                               1
     0.65
                               0
                                              5
[87]: #tambien puedo usar reset_index() para volver a los indices por defecto yu
     →mantener el indice actual como columna:
     df = df.reset_index()
     df.head()
[87]:
        Chance of Admit
                           GRE Score
                                      TOEFL Score University Rating
                                                                       SOP
                                                                            LOR
                                                                                   \
     0
                    0.92
                                 337
                                              118
                                                                    4
                                                                       4.5
                                                                              4.5
                    0.76
     1
                                 324
                                              107
                                                                    4
                                                                       4.0
                                                                              4.5
     2
                    0.72
                                 316
                                              104
                                                                       3.0
                                                                              3.5
                                                                    3
     3
                    0.80
                                 322
                                              110
                                                                    3
                                                                       3.5
                                                                              2.5
     4
                    0.65
                                 314
                                                                    2
                                                                       2.0
                                              103
                                                                              3.0
        CGPA Research Serial number
     0 9.65
                     1
     1 8.87
                     1
                                     2
     2 8.00
                     1
                                     3
     3 8.67
                                     4
                     1
     4 8.21
                                     5
                     0
[88]: #importo otro csv para mostrar index multi nivel
     df = pd.read_csv('census.csv')
     df.head()
```

0.76

1

2

```
[88]:
        SUMLEV
                REGION DIVISION STATE COUNTY
                                                    STNAME
                                                                    CTYNAME. \
     0
            40
                      3
                                6
                                                0 Alabama
                                                                    Alabama
                                       1
            50
                      3
                                6
                                       1
     1
                                                1
                                                   Alabama
                                                           Autauga County
     2
            50
                      3
                                6
                                       1
                                                3 Alabama
                                                            Baldwin County
                      3
                                6
     3
            50
                                                   Alabama
                                                            Barbour County
     4
            50
                      3
                                6
                                                   Alabama
                                                                Bibb County
        CENSUS2010POP
                       ESTIMATESBASE2010 POPESTIMATE2010
                                                                   RDOMESTICMIG2011
     0
              4779736
                                  4780127
                                                    4785161
                                                                           0.002295
     1
                54571
                                    54571
                                                      54660
                                                              . . .
                                                                           7.242091
     2
               182265
                                   182265
                                                     183193
                                                                          14.832960
     3
                27457
                                    27457
                                                      27341
                                                                          -4.728132
     4
                22915
                                    22919
                                                      22861
                                                                          -5.527043
        RDOMESTICMIG2012 RDOMESTICMIG2013 RDOMESTICMIG2014 RDOMESTICMIG2015
     0
               -0.193196
                                   0.381066
                                                      0.582002
                                                                        -0.467369
     1
               -2.915927
                                  -3.012349
                                                      2.265971
                                                                        -2.530799
     2
               17.647293
                                  21.845705
                                                     19.243287
                                                                        17.197872
     3
               -2.500690
                                  -7.056824
                                                     -3.904217
                                                                       -10.543299
               -5.068871
                                  -6.201001
                                                     -0.177537
                                                                         0.177258
        RNETMIG2011 RNETMIG2012 RNETMIG2013 RNETMIG2014 RNETMIG2015
     0
           1.030015
                        0.826644
                                      1.383282
                                                    1.724718
                                                                 0.712594
           7.606016
                       -2.626146
                                     -2.722002
                                                    2.592270
                                                                -2.187333
     1
     2
          15.844176
                       18.559627
                                     22.727626
                                                   20.317142
                                                                 18.293499
     3
          -4.874741
                       -2.758113
                                     -7.167664
                                                   -3.978583
                                                                -10.543299
                       -4.363636
                                     -5.403729
          -5.088389
                                                    0.754533
                                                                  1.107861
     [5 rows x 100 columns]
[90]: df['SUMLEV'].unique() #veo los valores unicos de la columna sumlev
[90]: array([40, 50])
[92]: #me quedo solo con los valores de sumlev iqual a 50
     df = df[df['SUMLEV'] == 50]
     df.head()
[92]:
        SUMLEV
                REGION DIVISION
                                  STATE COUNTY
                                                    STNAME
                                                                    CTYNAME
            50
                      3
                                6
                                                1 Alabama
                                                            Autauga County
     2
            50
                      3
                                6
                                       1
                                                3 Alabama
                                                            Baldwin County
     3
            50
                      3
                                6
                                       1
                                                5
                                                   Alabama
                                                            Barbour County
                      3
                                6
                                       1
                                                   Alabama
                                                               Bibb County
     4
            50
                                                7
                                6
     5
            50
                      3
                                       1
                                                   Alabama
                                                             Blount County
        CENSUS2010POP
                       ESTIMATESBASE2010 POPESTIMATE2010
                                                                   RDOMESTICMIG2011
     1
                54571
                                    54571
                                                      54660
                                                                           7.242091
     2
                                                     183193
               182265
                                   182265
                                                             . . .
                                                                          14.832960
     3
                27457
                                    27457
                                                      27341
                                                             . . .
                                                                          -4.728132
```

```
5
                57322
                                    57322
                                                     57373 ...
                                                                          1.807375
        RDOMESTICMIG2012
                          RDOMESTICMIG2013 RDOMESTICMIG2014 RDOMESTICMIG2015
     1
               -2.915927
                                 -3.012349
                                                     2.265971
                                                                       -2.530799
     2
               17.647293
                                 21.845705
                                                    19.243287
                                                                       17.197872
                                                    -3.904217
     3
               -2.500690
                                 -7.056824
                                                                      -10.543299
     4
               -5.068871
                                 -6.201001
                                                    -0.177537
                                                                        0.177258
               -1.177622
                                 -1.748766
                                                    -2.062535
                                                                       -1.369970
        RNETMIG2011 RNETMIG2012 RNETMIG2013 RNETMIG2014 RNETMIG2015
     1
           7.606016
                      -2.626146
                                    -2.722002
                                                   2.592270
                                                               -2.187333
     2
          15.844176
                       18.559627
                                    22.727626
                                                  20.317142
                                                               18.293499
     3
          -4.874741
                       -2.758113
                                    -7.167664
                                                  -3.978583
                                                              -10.543299
     4
          -5.088389
                       -4.363636
                                    -5.403729
                                                   0.754533
                                                                1.107861
           1.859511
                       -0.848580
                                    -1.402476
                                                  -1.577232
                                                               -0.884411
     [5 rows x 100 columns]
[93]: #vamos a limpiar un poco y quedarnos solo con las columnas que nos interesan:
     columns_to_keep = ['STNAME', 'CTYNAME', 'BIRTHS2010', 'BIRTHS2011', |
      \hookrightarrow 'BIRTHS2012',
                         'BIRTHS2013', 'BIRTHS2014', 'BIRTHS2015', 'POPESTIMATE2013',
     → 'POPESTIMATE2014', 'POPESTIMATE2015']
     df = df[columns_to_keep]
     df.head()
[93]:
         STNAME
                        CTYNAME BIRTHS2010 BIRTHS2011 BIRTHS2012
                                                                      BIRTHS2013 \
     1 Alabama Autauga County
                                                     636
                                                                              574
                                         151
                                                                  615
     2 Alabama Baldwin County
                                                                 2092
                                         517
                                                    2187
                                                                             2160
     3 Alabama Barbour County
                                          70
                                                     335
                                                                  300
                                                                              283
     4 Alabama
                    Bibb County
                                          44
                                                     266
                                                                  245
                                                                              259
     5 Alabama Blount County
                                                     744
                                                                 710
                                                                              646
                                         183
        BIRTHS2014 BIRTHS2015 POPESTIMATE2013 POPESTIMATE2014 POPESTIMATE2015
     1
               623
                           600
                                           55038
                                                            55290
                                                                              55347
     2
              2186
                          2240
                                          195126
                                                           199713
                                                                             203709
               260
                           269
                                           26973
                                                            26815
                                                                              26489
     4
               247
                           253
                                           22512
                                                            22549
                                                                              22583
     5
               618
                           603
                                           57734
                                                            57658
                                                                              57673
[94]: #ahora vamos a asignar dos index
     df = df.set_index(['STNAME', 'CTYNAME'])
     df.head()
[94]:
                             BIRTHS2010 BIRTHS2011 BIRTHS2012 BIRTHS2013 \
     STNAME CTYNAME
     Alabama Autauga County
                                                 636
                                                                          574
                                     151
                                                             615
                                                2187
                                                            2092
                                                                         2160
             Baldwin County
                                    517
```

22919

22861 ...

-5.527043

4

22915

```
Barbour County
                                     70
                                                 335
                                                             300
                                                                          283
                                                 266
                                                                          259
             Bibb County
                                     44
                                                             245
             Blount County
                                    183
                                                 744
                                                             710
                                                                         646
                             BIRTHS2014 BIRTHS2015 POPESTIMATE2013 \
     STNAME CTYNAME
     Alabama Autauga County
                                    623
                                                 600
                                                                55038
             Baldwin County
                                   2186
                                                2240
                                                               195126
             Barbour County
                                                 269
                                                                26973
                                    260
             Bibb County
                                                 253
                                                                22512
                                    247
             Blount County
                                                 603
                                                                57734
                                    618
                             POPESTIMATE2014 POPESTIMATE2015
     STNAME CTYNAME
                                       55290
                                                         55347
     Alabama Autauga County
                                                        203709
             Baldwin County
                                      199713
             Barbour County
                                        26815
                                                         26489
             Bibb County
                                        22549
                                                         22583
             Blount County
                                        57658
                                                         57673
[96]: #puedo consultar poniendo ambos indices, deben estar en orden
     df.loc['Michigan', 'Washtenaw County'] #pido los datos del condado de washtenaw_
      → (estado de michigan)
[96]: BIRTHS2010
                           977
    BIRTHS2011
                          3826
    BIRTHS2012
                          3780
    BIRTHS2013
                          3662
    BIRTHS2014
                          3683
    BIRTHS2015
                          3709
    POPESTIMATE2013
                        354289
    POPESTIMATE2014
                        357029
    POPESTIMATE2015
                        358880
     Name: (Michigan, Washtenaw County), dtype: int64
[99]: #tambien puedo seleccionar dos condados para comparar los datos:
     df.loc[[('Michigan', 'Washtenaw County'), ('Michigan', 'Wayne County')]]
[99]:
                                BIRTHS2010 BIRTHS2011 BIRTHS2012 BIRTHS2013
     STNAME
              CTYNAME
     Michigan Washtenaw County
                                       977
                                                   3826
                                                               3780
                                                                            3662
              Wayne County
                                      5918
                                                  23819
                                                              23270
                                                                           23377
                                BIRTHS2014 BIRTHS2015 POPESTIMATE2013
              CTYNAME
     STNAME
    Michigan Washtenaw County
                                      3683
                                                   3709
                                                                  354289
              Wayne County
                                     23607
                                                  23586
                                                                 1775713
                                POPESTIMATE2014 POPESTIMATE2015
```

STNAME CTYNAME

Michigan Washtenaw County 357029 358880 Wayne County 1766008 1759335

7 Missing Values

```
[100]: import pandas as pd
      df = pd.read_csv('class_grades.csv')
      df.head(10)
[100]:
         Prefix
                 Assignment
                              Tutorial
                                         Midterm
                                                  TakeHome
                                                             Final
              5
                       57.14
                                 34.09
                                           64.38
                                                      51.48
                                                             52.50
      0
      1
              8
                       95.05
                                105.49
                                           67.50
                                                      99.07
                                                             68.33
      2
              8
                       83.70
                                 83.17
                                             NaN
                                                      63.15
                                                             48.89
      3
              7
                         NaN
                                    NaN
                                           49.38
                                                     105.93
                                                             80.56
      4
              8
                       91.32
                                 93.64
                                           95.00
                                                     107.41
                                                             73.89
              7
      5
                       95.00
                                 92.58
                                           93.12
                                                      97.78
                                                             68.06
      6
              8
                       95.05
                                102.99
                                                      99.07
                                           56.25
                                                             50.00
              7
      7
                       72.85
                                 86.85
                                           60.00
                                                        NaN
                                                             56.11
      8
              8
                       84.26
                                           47.50
                                                      18.52
                                 93.10
                                                             50.83
      9
              7
                       90.10
                                 97.55
                                           51.25
                                                      88.89
                                                             63.61
[101]: #utilizo la funcion isnull() para crear una mascara:
      mask = df.isnull()
      mask.head(10)
[101]:
         Prefix
                 Assignment Tutorial Midterm TakeHome Final
          False
                       False
                                 False
                                           False
                                                      False False
      1
          False
                       False
                                 False
                                           False
                                                      False False
      2
          False
                       False
                                 False
                                            True
                                                     False False
          False
      3
                        True
                                  True
                                           False
                                                      False False
      4
          False
                                           False
                                                     False False
                       False
                                 False
      5
          False
                       False
                                 False
                                           False
                                                     False False
      6
          False
                       False
                                 False
                                           False
                                                      False False
      7
          False
                       False
                                 False
                                           False
                                                       True False
      8
          False
                       False
                                 False
                                           False
                                                     False False
          False
                       False
                                 False
                                           False
                                                      False False
[102]: #con el dropna() elimino todas las filas que tienen algn valor vacio
      df.dropna().head(10)
[102]:
          Prefix
                  Assignment
                               Tutorial Midterm
                                                   TakeHome
                                                             Final
               5
                        57.14
                                   34.09
                                            64.38
                                                       51.48
                                                              52.50
      0
               8
                        95.05
                                            67.50
      1
                                 105.49
                                                       99.07
                                                              68.33
      4
               8
                        91.32
                                   93.64
                                            95.00
                                                      107.41 73.89
                                                       97.78 68.06
      5
               7
                        95.00
                                  92.58
                                            93.12
      6
               8
                        95.05
                                 102.99
                                            56.25
                                                       99.07
                                                              50.00
      8
               8
                        84.26
                                  93.10
                                            47.50
                                                       18.52
                                                              50.83
```

```
10
               7
                       80.44
                                 90.20
                                          75.00
                                                     91.48 39.72
      12
               8
                       97.16
                                103.71
                                          72.50
                                                     93.52
                                                            63.33
               7
                       91.28
                                          81.25
      13
                                 83.53
                                                     99.81 92.22
[108]: #con fillna() puede rellenar los valores nulos con algun valor:
      df.fillna(0, inplace = True) #el inplace hace que se modifiquen los datos⊔
       →originales, no devuelve una copia
      df.head(10)
[108]:
         Prefix Assignment Tutorial Midterm TakeHome Final
      0
              5
                      57.14
                                34.09
                                         64.38
                                                    51.48
                                                          52.50
              8
                      95.05
                               105.49
      1
                                         67.50
                                                    99.07
                                                           68.33
      2
              8
                      83.70
                                83.17
                                          0.00
                                                    63.15 48.89
      3
              7
                       0.00
                                 0.00
                                         49.38
                                                   105.93 80.56
      4
              8
                      91.32
                                93.64
                                         95.00
                                                   107.41 73.89
      5
              7
                      95.00
                                92.58
                                         93.12
                                                    97.78 68.06
                      95.05
      6
              8
                               102.99
                                         56.25
                                                    99.07
                                                           50.00
      7
              7
                      72.85
                                86.85
                                         60.00
                                                    0.00 56.11
              8
                      84.26
      8
                                93.10
                                         47.50
                                                    18.52 50.83
              7
                      90.10
                                97.55
                                         51.25
      9
                                                    88.89 63.61
[109]: df = pd.read_csv('log.csv')
      df.head(10)
[109]:
               time
                       user
                                  video
                                         playback position paused
                                                                    volume
      0 1469974424
                     cheryl intro.html
                                                          5
                                                             False
                                                                      10.0
      1 1469974454 cheryl intro.html
                                                               NaN
                                                                       NaN
                                                          6
      2 1469974544
                     cheryl intro.html
                                                          9
                                                               NaN
                                                                       NaN
      3 1469974574
                     cheryl intro.html
                                                         10
                                                               NaN
                                                                       NaN
      4 1469977514
                        bob intro.html
                                                          1
                                                               NaN
                                                                       NaN
      5 1469977544
                        bob intro.html
                                                                       NaN
                                                          1
                                                               NaN
      6 1469977574
                        bob intro.html
                                                          1
                                                               NaN
                                                                       NaN
      7 1469977604
                        bob intro.html
                                                          1
                                                               NaN
                                                                       NaN
      8 1469974604 cheryl intro.html
                                                               NaN
                                                                       NaN
                                                         11
      9 1469974694
                     cheryl intro.html
                                                         14
                                                               NaN
                                                                       NaN
[110]: #en el sistema que tomo estos datos, los valores de paused y volume no sel
       →actualizan si no sufren cambios. Para ello se puede
      #utilizar ffill (foward filling) que actualiza un na de una celda en particular
       →por el valor de la fila anterior. bfill
      #(backward filling) es lo mismo pero al reves.
[111]: df = df.set_index('time') #seteo al tiempo de indice
      df = df.sort_index() #ordeno por el indice
      df.head()
[111]:
                                  video playback position paused
                    user
                                                                    volume
      time
                                                                      10.0
      1469974424 cheryl
                             intro.html
                                                          5 False
```

9

7

90.10

97.55

51.25

88.89

63.61

```
1469974424
                          advanced.html
                                                         23 False
                                                                       10.0
                     sue
                                                                        NaN
      1469974454 cheryl
                              intro.html
                                                          6
                                                               NaN
      1469974454
                     sue
                          advanced.html
                                                         24
                                                                NaN
                                                                        NaN
      1469974484 cheryl
                             intro.html
                                                          7
                                                                NaN
                                                                        NaN
[112]: #aca podemos ver que el index no tiene que ser necesariamente unico. Ahora
      →vamos a hacer un index multi nivel con time y user:
      df = df.reset_index()
      df = df.set_index(['time', 'user'])
      df.head()
[112]:
                                  video playback position paused volume
      time
                 user
      1469974424 cheryl
                                                           False
                                                                      10.0
                            intro.html
                                                         5
                                                        23
                                                           False
                                                                      10.0
                 sue
                         advanced.html
                             intro.html
                                                         6
                                                              NaN
                                                                       NaN
      1469974454 cheryl
                 sue
                         advanced.html
                                                        24
                                                              NaN
                                                                       NaN
      1469974484 cheryl
                            intro.html
                                                         7
                                                              NaN
                                                                       NaN
[114]: #ahora que la lista esta ordenada puedo usar ffill:
      df = df.fillna(method = 'ffill')
      df.head()
[114]:
                                  video playback position paused volume
      time
                 user
      1469974424 cheryl
                            intro.html
                                                         5
                                                             False
                                                                       10.0
                                                             False
                         advanced.html
                                                        23
                                                                       10.0
                 sue
                            intro.html
                                                             False
                                                                       10.0
      1469974454 cheryl
                                                         6
                         advanced.html
                                                        24
                                                             False
                                                                       10.0
                 sue
      1469974484 cheryl
                            intro.html
                                                         7
                                                             False
                                                                       10.0
[115]: #otros ejemplos con el siguiente df:
      df = pd.DataFrame({'A': [1, 1, 2, 3, 4],
                          'B': [3, 6, 3, 8, 9],
                          'C': ['a', 'b', 'c', 'd', 'e']})
      df
[115]:
         Α
            В
              C
            3 a
         1
         1 6 b
      1
      2
        2 3 c
      3
         3
            8 d
         4 9
[117]: df.replace(1, 100) #con replace indico que quiero reemplazar los 1 por 100
[117]:
              В
                 C
           Α
         100 3 a
      0
        100 6 b
      1
      2
           2
              3
           3 8
      3
                 d
```

4 4 9 e [119]: df.replace([1, 3], [100, 300]) #reemplazo los 1 por 100 y los 3 por 300 [119]: В C 100 300 0 a 100 1 6 b 2 2 300 С 300 8 3 d 4 4 9 е [3]: import pandas as pd [17]: #volvems al archivo log df = pd.read_csv('log.csv') df [17]: playback position paused time user video volume 1469974424 5 0 cheryl intro.html False 10.0 6 1 1469974454 cheryl intro.html NaN NaN 2 1469974544 cheryl intro.html 9 NaN NaN 3 1469974574 10 NaN cheryl intro.html NaN 4 1 NaN 1469977514 bob intro.html NaN NaN 5 1469977544 bob intro.html 1 NaN 6 1469977574 bob intro.html 1 NaN NaN 7 1469977604 bob intro.html 1 NaN NaN 8 1469974604 cheryl intro.html 11 NaN NaN 9 14 1469974694 cheryl intro.html NaN NaN 10 1469974724 cheryl intro.html 15 NaN NaN 1469974454 advanced.html 24 NaN 11 sue NaN 25 NaN 12 1469974524 advanced.html NaN sue 13 1469974424 advanced.html 23 False 10.0 sue 14 1469974554 advanced.html 26 NaN NaN sue 27 NaN 15 1469974624 sue advanced.html NaN 16 1469974654 advanced.html 28 NaN 5.0 sue 17 advanced.html 29 NaN NaN 1469974724 sue 7 NaN 18 1469974484 cheryl intro.html NaN 19 1469974514 cheryl intro.html 8 NaN NaN 20 1469974754 advanced.html 30 NaN NaN sue 21 1469974824 sue advanced.html 31 NaN NaN 22 1469974854 advanced.html 32 NaN sue NaN NaN 23 1469974924 sue advanced.html 33 NaN 24 1469977424 1 True 10.0 bob intro.html 1 NaN 25 1469977454 bob intro.html NaN 26 1469977484 1 NaN NaN bob intro.html 27 1 NaN 1469977634 bob intro.html NaN 28 1469977664 bob intro.html 1 NaN NaN 29 1469974634 cheryl 12 NaN NaN intro.html 30 1469974664 cheryl intro.html 13 NaN NaN

```
31 1469977694 bob intro.html 1 NaN NaN 32 1469977724 bob intro.html 1 NaN NaN
```

[18]: #tambien se pueden hacer reemplazos usando regex. Supongamos que queremos□

→ cambiar todos los valores de video terminados en

#'.html' por 'webpage'.

df.replace(to_replace = '.*.html\$', value = 'webpage', regex = True)

#el \$ es para coincidir con el final de la cadena mientras que el .* es para□

→ coincidir con todo el resto, sea lo que sea

[18]:		time	user	video	playback	position	paused	volume
	0	1469974424	cheryl	webpage		5	False	10.0
	1	1469974454	cheryl	webpage		6	NaN	NaN
	2	1469974544	cheryl	webpage		9	NaN	NaN
	3	1469974574	cheryl	webpage		10	NaN	NaN
	4	1469977514	bob	webpage		1	NaN	NaN
	5	1469977544	bob	webpage		1	NaN	NaN
	6	1469977574	bob	webpage		1	NaN	NaN
	7	1469977604	bob	webpage		1	NaN	NaN
	8	1469974604	cheryl	webpage		11	NaN	NaN
	9	1469974694	cheryl	webpage		14	NaN	NaN
	10	1469974724	cheryl	webpage		15	NaN	NaN
	11	1469974454	sue	webpage		24	NaN	NaN
	12	1469974524	sue	webpage		25	NaN	NaN
	13	1469974424	sue	webpage		23	False	10.0
	14	1469974554	sue	webpage		26	NaN	NaN
	15	1469974624	sue	webpage		27	NaN	NaN
	16	1469974654	sue	webpage		28	NaN	5.0
	17	1469974724	sue	webpage		29	NaN	NaN
	18	1469974484	cheryl	webpage		7	NaN	NaN
	19	1469974514	cheryl	webpage		8	NaN	NaN
	20	1469974754	sue	webpage		30	NaN	NaN
	21	1469974824	sue	webpage		31	NaN	NaN
	22	1469974854	sue	webpage		32	NaN	NaN
	23	1469974924	sue	webpage		33	NaN	NaN
	24	1469977424	bob	webpage		1	True	10.0
	25	1469977454	bob	webpage		1	NaN	NaN
	26	1469977484	bob	webpage		1	NaN	NaN
	27	1469977634	bob	webpage		1	NaN	NaN
	28	1469977664	bob	webpage		1	NaN	NaN
	29	1469974634	cheryl	webpage		12	NaN	NaN
	30	1469974664	cheryl	webpage		13	NaN	NaN
	31	1469977694	bob	webpage		1	NaN	NaN
	32	1469977724	bob	webpage		1	NaN	NaN

8 Example: Manipulating DataFrame

```
[9]: import pandas as pd
     df = pd.read_csv('presidents.csv')
     df.head()
 [9]:
        #
                   President
                                          Born
                                                    Age atstart of presidency \
        1
           George Washington Feb 22, 1732[a]
                                                57ayears, 67adaysApr 30, 1789
     1
        2
                  John Adams
                              Oct 30, 1735[a]
                                                61 ayears, 125 adays Mar 4, 1797
     2
       3
            Thomas Jefferson Apr 13, 1743[a]
                                                57 ayears, 325 adays Mar 4, 1801
               James Madison Mar 16, 1751[a]
                                                57ayears, 353adaysMar 4, 1809
     3
       4
     4 5
                James Monroe
                                  Apr 28, 1758
                                                58ăyears, 310ădaysMar 4, 1817
              Age atend of presidency Post-presidencytimespan
                                                                         Died
         65 ayears, 10 adays Mar 4, 1797
                                             2ăyears, 285ădays
     0
                                                                Dec 14, 1799
     1 65 ayears, 125 adays Mar 4, 1801
                                            25ăyears, 122ădays
                                                                  Jul 4, 1826
     2 65 ayears, 325 adays Mar 4, 1809
                                            17ăyears, 122ădays
                                                                  Jul 4, 1826
     3 65 ayears, 353 adays Mar 4, 1817
                                            19ăyears, 116ădays
                                                                 Jun 28, 1836
     4 66 ayears, 310 adays Mar 4, 1825
                                             6ăyears, 122ădays
                                                                  Jul 4, 1831
                       Age
     0 67 ayears, 295 adays
     1 90 ayears, 247 adays
     2 83 ayears, 82 adays
     3 85 ayears, 104 adays
        73 ayears, 67 adays
[10]: #vamos a separar el nombre y apelldio a los presidentes
     df['First'] = df['President'] #copio la columna presidente y le pongo first
     df['First'] = df['First'].replace('[].*', '', regex = True )
     #con '[].*' le diqo que matchee con todo lo que esta despues del espacio y lou
      →cambie por el segundo parametro ''.
     df.head()
[10]:
        #
                   President
                                          Born
                                                    Age atstart of presidency \
           George Washington Feb 22, 1732[a] 57ăyears, 67ădaysApr 30, 1789
     0
        1
     1
        2
                  John Adams
                              Oct 30, 1735[a]
                                                61 ayears, 125 adays Mar 4, 1797
     2
       3
                                                57ayears, 325adaysMar 4, 1801
            Thomas Jefferson Apr 13, 1743[a]
     3
       4
               James Madison
                              Mar 16, 1751[a]
                                                57 ayears, 353 adays Mar 4, 1809
     4 5
                                                58ăyears, 310ădaysMar 4, 1817
                James Monroe
                                  Apr 28, 1758
              Age atend of presidency Post-presidencytimespan
                                                                         Died
     0
         65ăyears, 10ădaysMar 4, 1797
                                             2ăyears, 285ădays
                                                                Dec 14, 1799
     1 65ăyears, 125ădaysMar 4, 1801
                                            25ăyears, 122ădays
                                                                  Jul 4, 1826
     2 65ăyears, 325ădaysMar 4, 1809
                                            17ăyears, 122ădays
                                                                  Jul 4, 1826
     3 65 ayears, 353 adays Mar 4, 1817
                                            19ăyears, 116ădays
                                                                 Jun 28, 1836
                                             6ăyears, 122ădays
     4 66 ayears, 310 adays Mar 4, 1825
                                                                  Jul 4, 1831
```

```
First
     0 67ăyears, 295ădays
                            George
     1 90 ayears, 247 adays
                              John
     2 83 ayears, 82 adays
                            Thomas
     3 85 ayears, 104 adays
                             James
        73 ayears, 67 adays
                             James
[11]: #hay mejores maneras de hacer esto, como la funcion apply(). Vamos a borrar la
     →columna first:
     del(df['First'])
     def splitname(row): #creo funcion
         row['First'] = row['President'].split(' ')[0] #extraigo el primer nombre y⊔
      → qenero la nueva columna
         row['Last'] = row['President'].split(' ')[-1] #extraigo el apellido yu
      → genero la nueva columna
         return(row)
     df = df.apply(splitname, axis = 'columns')
     df.head()
[11]:
                   President
                                         Born
                                                    Age atstart of presidency \
     0
       1
          George Washington Feb 22, 1732[a] 57ăyears, 67ădaysApr 30, 1789
                  John Adams Oct 30, 1735[a] 61 ayears, 125 adays Mar 4, 1797
     1
     2 3
            Thomas Jefferson Apr 13, 1743[a]
                                               57ayears, 325adaysMar 4, 1801
     3 4
               James Madison Mar 16, 1751[a]
                                               57ayears, 353adaysMar 4, 1809
     4 5
                James Monroe
                                 Apr 28, 1758
                                               58ăyears, 310ădaysMar 4, 1817
              Age atend of presidency Post-presidencytimespan
                                                                        Died \
     0
         65 ayears, 10 adays Mar 4, 1797
                                            2ăyears, 285ădays Dec 14, 1799
     1 65ăyears, 125ădaysMar 4, 1801
                                           25 ayears, 122 adays
                                                                 Jul 4, 1826
     2 65ăyears, 325ădaysMar 4, 1809
                                           17ăyears, 122ădays
                                                                 Jul 4, 1826
                                           19ăyears, 116ădays
     3 65 ayears, 353 adays Mar 4, 1817
                                                                Jun 28, 1836
     4 66 ayears, 310 adays Mar 4, 1825
                                            6ăyears, 122ădays
                                                                 Jul 4, 1831
                       Age
                             First
                                          Last
     0 67ăyears, 295ădays
                            George
                                    Washington
     1 90 ayears, 247 adays
                              John
                                         Adams
     2
       83ăyears, 82ădays
                           Thomas
                                     Jefferson
     3 85 ayears, 104 adays
                             James
                                       Madison
        73 ayears, 67 adays
                             James
                                        Monroe
[12]: #elimino las columnas first y last:
     del(df['First'])
     del(df['Last'])
[13]: #ahora vamos a utilizar la funcion extract():
     pattern = '(^[\w]*)(?:.*)([\w]**)' #le diqo que quiero 3 grupos. El primero
      →anclado al inicio, cualquier tipo de caracteres.
```

```
#Al segundo le pongo ?: porque este grupo no quiero retornarlo, no me interesa_{f L}
      → (cualquier numero de caracteres seguido de un
     #espacio). En el tercero quiero cualquier tipo de caracteres que esten anclados⊔
      \rightarrow al final.
     df['President'].str.extract(pattern).head() #utilizo extract pasandole elu
      \rightarrow patron
[13]:
        George
                Washington
          John
                     Adams
     1
     2
      Thomas
                 Jefferson
     3
         James
                   Madison
                    Monroe
         James
[15]: #si le pongo nombre a los grupos del patron, se pasaran a los nombres de lasu
      →columnas.
     pattern = '(?P<First>^[\w]*)(?:.*)(?P<Last>[\w]*$)'
     names = df['President'].str.extract(pattern).head()
     names
[15]:
        First
                      Last
     0 George
                Washington
          John
                     Adams
     1
      Thomas
                 Jefferson
     2
     3
         James
                   Madison
         James
                    Monroe
[16]: #ahora copio esto al df original:
     df['First'] = names['First']
     df['Last'] = names['Last']
     df.head()
[16]:
                   President
                                                    Age atstart of presidency \
                                          Born
        1
           George Washington Feb 22, 1732[a] 57ayears, 67adaysApr 30, 1789
     1
       2
                  John Adams Oct 30, 1735[a]
                                                61 ayears, 125 adays Mar 4, 1797
     2 3
                                                57ăyears, 325ădaysMar 4, 1801
            Thomas Jefferson Apr 13, 1743[a]
     3 4
               James Madison Mar 16, 1751[a]
                                                57ăyears, 353ădaysMar 4, 1809
     4 5
                                  Apr 28, 1758 58ăyears, 310ădaysMar 4, 1817
                James Monroe
              Age atend of presidency Post-presidencytimespan
                                                                         Died \
                                                                 Dec 14, 1799
         65ăyears, 10ădaysMar 4, 1797
                                             2ăyears, 285ădays
     1 65ăyears, 125ădaysMar 4, 1801
                                            25 ayears, 122 adays
                                                                  Jul 4, 1826
     2 65 ayears, 325 adays Mar 4, 1809
                                            17ăyears, 122ădays
                                                                  Jul 4, 1826
     3 65 ayears, 353 adays Mar 4, 1817
                                            19ăyears, 116ădays
                                                                 Jun 28, 1836
                                             6ăyears, 122ădays
     4 66 ayears, 310 adays Mar 4, 1825
                                                                  Jul 4, 1831
                       Age
                             First
     0 67 ayears, 295 adays George Washington
```

```
1 90 ayears, 247 adays
                               John
                                          Adams
     2 83ăyears, 82ădays
                                      Jefferson
                           Thomas
     3 85 ayears, 104 adays
                              James
                                        Madison
        73 ayears, 67 adays
                              James
                                         Monroe
[17]: #Ahora vamos a limpiar la columna Born:
     df['Born'] = df['Born'].str.extract('([\w]{3} [\w]{1,2}, [\w]{4})')
     df['Born'].head()
[17]: 0
          Feb 22, 1732
          Oct 30, 1735
          Apr 13, 1743
     2
          Mar 16, 1751
     3
          Apr 28, 1758
     4
     Name: Born, dtype: object
[18]: #se puede mejorar el formato de la siguiente manera:
     df['Born'] = pd.to_datetime(df['Born']) #le cambio el formato usando una_
     →funcion de pandas
     df['Born'].head()
[18]: 0
         1732-02-22
     1
         1735-10-30
     2
         1743-04-13
     3
         1751-03-16
         1758-04-28
     Name: Born, dtype: datetime64[ns]
[20]: #para mas informacion de este tema ver los modulos str de pandas.
 []:
```